Análisis Eficiencia Fiscal y Salarios R-Studio

Se comparan los salarios de construcción en los municipios costeros y los no costeros. El objetivo es crear una prueba T (en donde se comparan los promedios de ambas categorías) y establecer si hay alguna evidencia estadísticamente significativa de que los cambios observados entre los promedios no son casualidad.

H0= No hay una diferencia estadísticamente significativa del salario de la categoría Naics (23) o construcción entre Municipios Costeros y Municipios No Costeros.

H1 = Si hay una diferencia estadísticamente significativa del salario de la categoría Naics (23) o construcción entre Municipios Costeros y Municipios No Costeros.

Se escoge la prueba de 2 colas debido a que inicialmente no contó con información suficiente para inferir que un grupo iba a ser mayor que el otro. El resultado fue el siguiente:

Mean group 0 = 13.91
Mean group 1 = 14.24
t= -1.1699
df= 69.836
p-value = 0.246

Los promedios de los grupos fueron de 13.91, y 14.24. El valor T fue de -1.169. El valor T resultó ser un valor pequeño para considerarlo estadísticamente significativo. Los grados de libertad (df) nos indicaron que la muestra contaba con 71 municipios- observaciones. El P-value es de 0.24, muy arriba del 0.05 requerido para considerar la diferencia entre ambos promedios- de categorías de municipios- como estadísticamente significativa. La interpretación ante esto es que no hay evidencia estadística que sustente que en los municipios costeros se paga mejor en la construcción. El código se encuentra en el Anejo 1 y los Resultados de Rstudio en Anejo2.

Análisis de varianza (ANOVA)

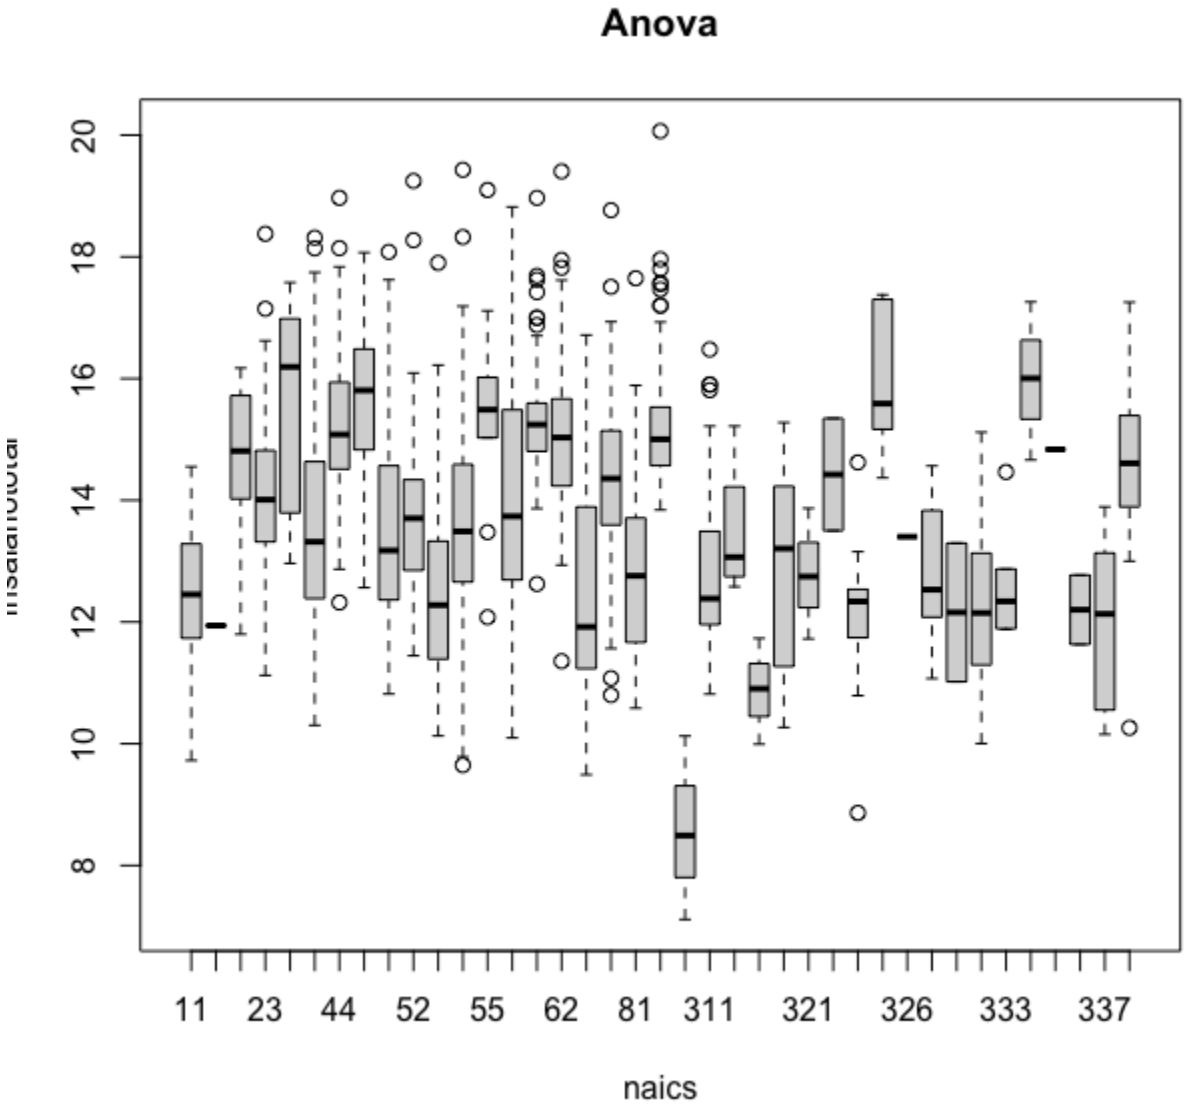
Se presenta la hipótesis nula y la alterna.

H0 = No hay una diferencia estadísticamente significativa entre promedios de Grupos Naics en base al logaritmo natural del salario total.

H1= La diferencia entre los Grupos Naics es estadísticamente significativa.

df= 38
p-value = 2e-16
F value = 25.46
Mean SQ = 1567
Mean SQ Residuals= 1.62
Df Residuals = 1186

El p-value de 2e-16, siendo mucho menor que 0.05 nos dice que la diferencia en salario total entre los diferentes NAICS es estadísticamente significativa. El F-Value es de 25.45 nos indica que la varianza entre grupos (NAICS) es mucho mayor a la varianza dentro de los mismos grupos. Esto hace que se pueda inferir estadísticamente que la diferencia no es por azar. Los grados de libertad (38) nos indican que hay 39 grupos naics que fueron incluidos en el modelo.. Para llegar al resultado, se identificaron outliers (ver anejo 3). Debido a que los residuales de las observaciones fueron 1186, se puede decir que el total de observaciones fue de 1225 : la suma de los Residuales (1186) y el total de categorías (39). Se creó un boxplot (ver anejo 5) que funcionó para eliminar los outliers y visualizar los promedios y outliers de los grupos naics. El código de Rstudio se encuentra en el (Anejo 6) y los resultados en el Anejo 6.1.



Ejercicio 2a

Regresión simple usando el índice de eficiencia fiscal ("fund_balance_all_funds_long_term_liabilities"), según medido en función de los fondos disponibles y todas las obligaciones, como variable dependiente y la población ("population").

Regresión simple entre la población de los municipios como variable independiente, y la eficiencia fiscal como variable dependiente. La hipótesis nula sería la siguiente (H0): No hay

una influencia estadísticamente significativa entre la eficiencia fiscal y la población. La hipótesis alterna es (H1): Existe una diferencia estadísticamente significativa entre la población y la eficiencia fiscal. Al correr los resultados obtenemos un P-value de 0.0172, Un T-Value de -2.44 y un Coeficiente de -0.25. A la variable de población se le aplicó un logaritmo natural para normalizar los valores.

P-Value : 0.0173
T-Value : -2.44
Coeficiente : -0.2587
R2: 0.07841

El P-Value indica que hay una relación estadísticamente significativa entre las variables ya que es menor que 0.05. El Coeficiente de -0.25 refleja que a medida que la población (x) aumenta 1%, Y se reduce -0.0026 unidades. La medida de R2 significa que la población solo explica el 7% de las variaciones en este modelo. Hay un 93% de factores que la población no puede explicar. El código de Rstudio está disponible en el Anejo 7. En resumen, la población muestra una relación estadísticamente significativa de forma inversa, es decir, a medida que la población aumenta, la eficiencia fiscal se reduce.

Regresión simple usando el índice de eficiencia fiscal ("fund_balance_all_funds_long_term_liabilities") como variable dependiente y el área superficial de cada municipio ("area_square_miles") como variable independiente.

Regresión simple entre el área superficial de los municipios como variable independiente, y la eficiencia fiscal como variable dependiente. La hipótesis nula sería la siguiente (H0): No hay una influencia estadísticamente significativa entre la eficiencia fiscal y el área superficial de los municipios. La hipótesis alterna es (H1): Existe una diferencia estadísticamente significativa entre el área superficial y la eficiencia fiscal. Se aplicó el logaritmo natural a la variable de área superficial. Al correr los resultados obtenemos un P-value de 0.54, Un T-Value de -0.609 y un Coeficiente de -0.09058.

P-Value : 0.54
T-Value : -0.609
Coeficiente : -0.09058
R2: 0.005266

El P-Value de 0.54 indica que no hay una relación estadísticamente significativa entre las variables ya que es mayor que 0.05. El Coeficiente de -0.09058 refleja que a medida que el area superficial(x) aumenta 1%, Y se mueve -0.0009058 unidades aunque no es significativo ya que el modelo tiene un P-value de 0.54. La medida de R2 significa que el area solo explica el .5% de las variaciones en este modelo. El código de Rstudio está disponible en el Anejo 8. En resumen, el área de los municipios no muestra una relación estadísticamente significativa con la eficiencia fiscal.

Regresión simple usando el índice de eficiencia fiscal ("fund_balance_all_funds_long_term_liabilities") como variable dependiente y el total de ingresos y ventas de cada municipio ("sum_of_sales_value_of_shipments_or_revenue") como variable independiente.

Regresión simple entre el ingreso y ventas de los municipios como variable independiente, y la eficiencia fiscal como variable dependiente. La hipótesis nula sería la siguiente (H0): No hay una influencia estadísticamente significativa entre la eficiencia fiscal y las ventas e ingresos a nivel municipal. La hipótesis alterna (H1) es: Existe una diferencia estadísticamente significativa entre las ventas e ingresos y la eficiencia fiscal. Se aplicó el logaritmo natural a la variable de ventas. Al correr los resultados obtenemos un P-value de 0.03, Un T-Value de -2.141y un Coeficiente de -0.109.

P-Value : 0.03
T-Value : -2.141
Coeficiente : -0.109
R2: 0.06148

El P-Value de 0.03 indica que si hay una relación estadísticamente significativa entre ventas y eficiencia fiscal ya que es menor que 0.05. El Coeficiente de -0.109 refleja que a medida que el las ventas e ingresos (x) aumenta 1%, Y se mueve -0.0019 unidades. La medida de R2 significa que el área explica el 6% de las variaciones en este modelo. El código de Rstudio está disponible en el Anejo 9 y los resultados en Anejo 10. En resumen, las ventas e ingresos de los municipios muestran una relación estadísticamente significativa con la eficiencia fiscal, aunque de forma inversa. Es decir, un aumento en ventas, reduce la eficiencia fiscal.

Regresión múltiple usando el índice de eficiencia fiscal ("fund_balance_all_funds_long_term_liabilities") como variable dependiente, y el área superficial de cada municipio ("area_square_miles") y el total de ingresos y ventas de cada municipio ("sum_of_sales_value_of_shipments_or_revenue") como variables independientes.

Regresión múltiple entre el ingreso y ventas, y área superficial de los municipios como variables independientes, y la eficiencia fiscal como variable dependiente. La hipótesis nula sería la siguiente (H0): No hay una relación estadísticamente significativa entre la eficiencia fiscal y las ventas e ingresos y área superficial a nivel municipal. La hipótesis alterna (H1) es: Existe una diferencia estadísticamente significativa entre la eficiencia fiscal, las ventas e ingresos y el área superficial a nivel municipal. Se aplicó el logaritmo natural a las variable de ventas e ingresos y al área superficial. Al correr los resultados obtenemos un P-value de 0.09, Un T-Value de -0.526, y un Coeficiente de -0.0765

P-Value : 0.09
T-Value : -0.526
Coeficiente de área : -0.0765
Coeficiente de ingresos: -0.10847
Error estándar área: 0.14544
Error estándar ingresos: 0.05
R2: 0.065

El P-Value de 0.60 indica que no hay una relación estadísticamente significativa entre ingresos y ventas, área y eficiencia fiscal - ya que es mayor al umbral de 0.05. El resultado indica que la variable del área superficial tiene un error estándar (0.14) mayor que el error estándar de ingresos (0.05), esto nos indica que la variable la regresión pudo predecir con mayor precisión ingresos y ventas y hubo más errores con la variable de área. La medida de R2 significa que el área e ingresos explican en conjunto el 6.5% de las variaciones en este modelo. El código de estudio está disponible en el Anejo 11 y los resultados en Anejo 12. En resumen, las ventas e ingresos y el área superficial en conjunto, no muestran una relación estadísticamente significativa con la eficiencia fiscal. Posiblemente la variable de área hace que el modelo sea menos preciso en esta regresión múltiple. E

Conclusiones

Basado en los resultados anteriores de las regresiones en donde se compara la población, area territorial y total de ventas como variables independientes y la Eficiencia Fiscal como variable dependiente, se puede inferir que los resultados no respaldan la consolidación municipal como estrategia para la eficiencia fiscal. La población fue estadisticamente significativa con un P-Value de 0.01, pero con una relación inversa indicando que la eficiencia fiscal disminuye según aumenta la población.

El área superficial no fué estadisticamente significativa (P-Value de 0.54). El total de ventas si fué significativo estadísticamente con un P-Value de 0.03 . Aún así, la relación fué inversa ya que el coeficiente fué de -0.10, lo que significa que a mayor aumento en las ventas: la eficiencia fiscal disminuye -según el modelo. En resumen, no hay evidencia empírica y/o estadística que sugiera que la consolidación municipal sería una solución para mejorar la eficiencia fiscal en los municipios.

Anejos

```r
library("foreign")

empleos <- read.csv("empleos_municipios.csv")


construccion <- empleos[which(empleos$naics == 23), ]


hist(construccion$lnsalariototal[which(construccion$costero==0)])
hist(construccion$lnsalariototal[which(construccion$costero==1)])


t.test(construccion$lnsalariototal ~ construccion$costero)
```

[1]*Anejo 1 _Rstudio Codigo- Ejercicio 1a*

1

```
        Welch Two Sample t-test

data:  construccion$lnsalariototal by construccion$costero
t = -1.1699, df = 69.836, p-value = 0.246
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -0.9269081  0.2415383
sample estimates:
mean in group 0 mean in group 1
       13.91948        14.26217
```

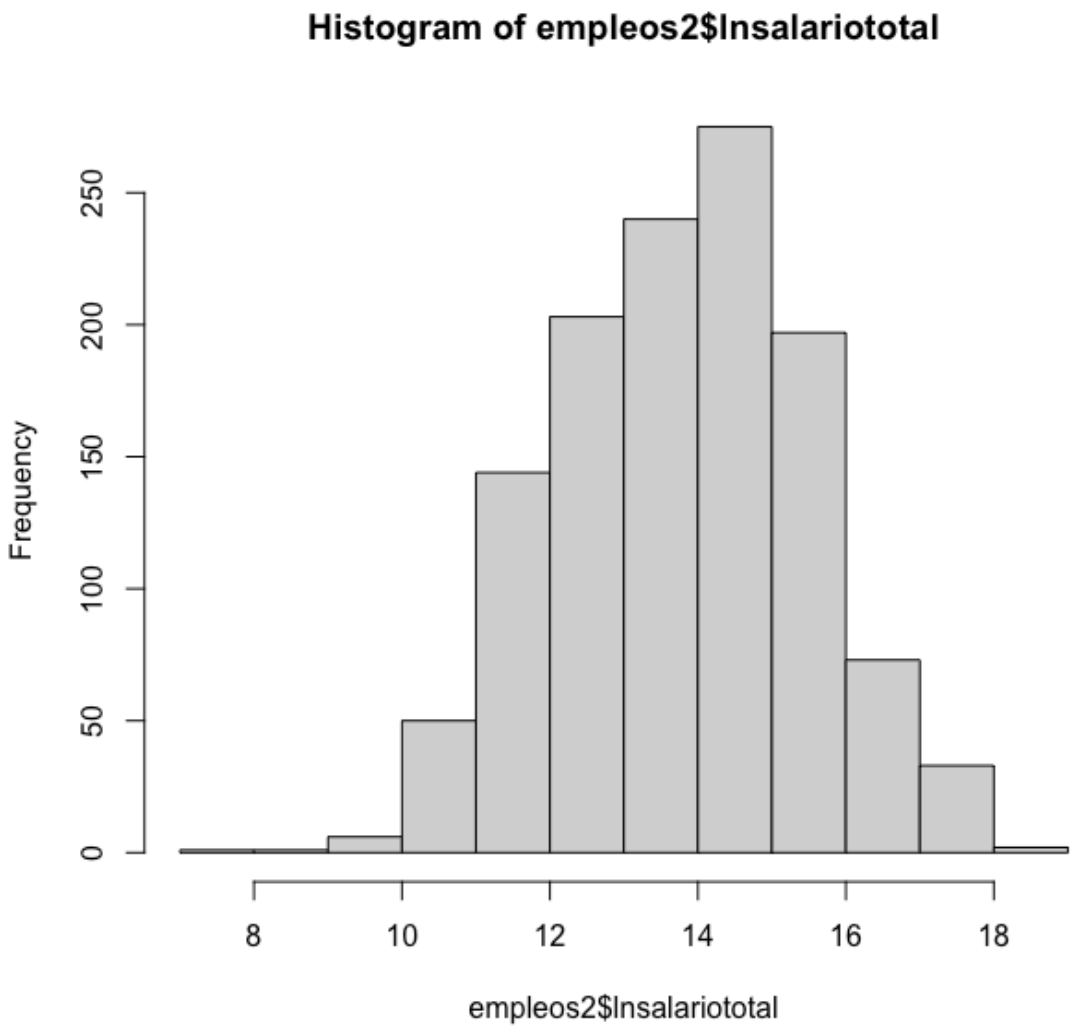
Anejo 2 - Resultados Rstudio

```
###Create boxplot of values
boxplot<-boxplot(empleos$lnsalariototal~empleos$naics,main="Anova",xlab="naics",ylab="lnsalariototal")

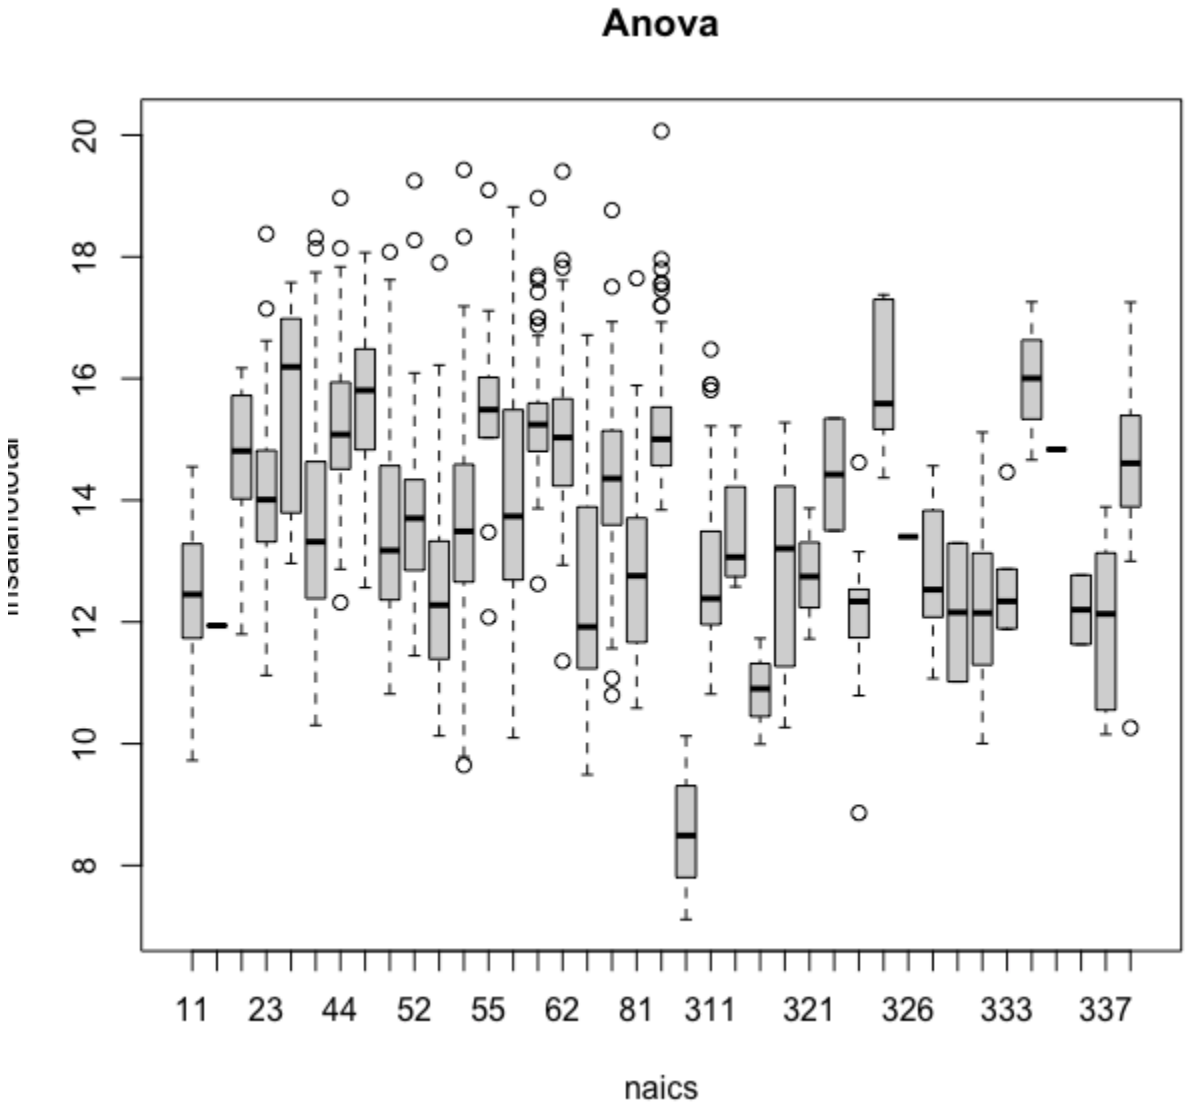
###Identify outliers
outliers = boxplot$out
empleos[empleos$lnsalariototal %in% outliers, c(2,11)]

###Remove outliers
empleos2<-empleos[-c(125, 288, 293, 426, 448, 456, 457, 461, 488, 525, 540, 545, 666, 669, 671, 1036, 1044, 1173, 1306, 1308,
1329, 1333, 1335, 1803, 1966, 2094, 2099, 2217, 2430, 2431, 2435, 2692, 2694, 2702, 2715, 2716, 2718, 2719,
2720, 2721, 2722, 2724, 2725, 2727, 2728, 2729, 2786, 2904, 2932, 3145),]
```

Anejo 3 - Eliminación de Outliers



Anejo 4 - Histograma Análisis ANOVA



[2]Anejo 5 - Ejercicio 1B_ Boxplot Grupos Naics

[2]

```r
##CHAPTER 11: ANALYSIS OF VARIANCE (ANOVA)##
###Openning packages
library("foreign")

###Creating data frame
empleos<-read.csv("empleos_municipios.csv")

###Convert "region" variable in factor form
empleos$naics <- as.factor(empleos$naics)


###Create boxplot of values
boxplot<-boxplot(empleos$lnsalariototal~empleos$naics,main="Anova",xlab="naics",ylab="lnsalariototal")

###Identify outliers
outliers = boxplot$out
empleos[empleos$lnsalariototal %in% outliers, c(2,11)]

###Remove outliers
empleos2<-empleos[-c(125, 288, 293, 426, 448, 456, 457, 461, 488, 525, 540, 545, 666, 669, 671, 1036, 1044, 1173, 1306, 1308,
1329, 1333, 1335, 1803, 1966, 2094, 2099, 2217, 2430, 2431, 2435, 2692, 2694, 2702, 2715, 2716, 2718, 2719,
2720, 2721, 2722, 2724, 2725, 2727, 2728, 2729, 2786, 2904, 2932, 3145),]


###Create histogram to test for normal distribution
hist(empleos2$lnsalariototal)

###Perform ANOVA
fit<-aov(empleos2$lnsalariototal~empleos2$naics)
summary(fit)
```

[3]Anejo 6 - Código de ANOVA - Ejercicio 1B.

```
                Df Sum Sq Mean Sq F value Pr(>F)
empleos2$naics   38   1567   41.23   25.46 <2e-16 ***
Residuals      1186   1920    1.62
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
2090 observations deleted due to missingness
```

Anejo 6.1 - Ejercicio 2b - Resultados Rstudio

3

```
Call:
lm(formula = fund_balance_all_funds_long_term_liabilities ~ log(population),
    data = muni_fiscal)

Residuals:
    Min      1Q  Median      3Q     Max
-1.0260 -0.4210 -0.1938  0.2450  2.1353

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)       3.2031     1.1036   2.902  0.00495 **
log(population)  -0.2587     0.1060  -2.440  0.01720 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.682 on 70 degrees of freedom
Multiple R-squared:  0.07841,   Adjusted R-squared:  0.06525
F-statistic: 5.956 on 1 and 70 DF,  p-value: 0.0172
```

Anejo 7- Regresión Simple - Rstudio_Ejercicio 2a.

```
Call:
lm(formula = fund_balance_all_funds_long_term_liabilities ~ log(area_square_miles),
    data = muni_fiscal)

Residuals:
    Min      1Q  Median      3Q     Max
-0.9133 -0.4272 -0.2901  0.2293  2.2165

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)            0.84780    0.54990   1.542    0.128
log(area_square_miles) -0.09058    0.14880  -0.609    0.545

Residual standard error: 0.7086 on 70 degrees of freedom
Multiple R-squared:  0.005266,  Adjusted R-squared:  -0.008945
F-statistic: 0.3706 on 1 and 70 DF,  p-value: 0.5447
```

Anejo 8 - Código Rstudio Ejercicio 2b.

```r
library(foreign)


#Aqui se extraen los datos
muni_fiscal<- read.csv("muni_econ_fiscal.csv")



#Regresion
results<-lm(fund_balance_all_funds_long_term_liabilities ~ log(sum_of_sales_value_of_shipments_or_revenue), data= muni_fiscal)

#Despliegue de resultados de regresion
summary(results)

#Numero de observaciones
(n <- nobs(results))
```

Anejo 9- Código Rstudio Ejercicio 2C

```
Call:
lm(formula = fund_balance_all_funds_long_term_liabilities ~ log(sum_of_sales_value_of_shipments_or_revenue),
    data = muni_fiscal)

Residuals:
    Min      1Q  Median      3Q     Max
-1.0646 -0.4108 -0.2111  0.2251  2.1990

Coefficients:
                                            Estimate Std. Error t value Pr(>|t|)
(Intercept)                                  2.08898    0.73862   2.828   0.0061 **
log(sum_of_sales_value_of_shipments_or_revenue) -0.10972    0.05124  -2.141   0.0357 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.6882 on 70 degrees of freedom
Multiple R-squared:  0.06148,   Adjusted R-squared:  0.04807
F-statistic: 4.585 on 1 and 70 DF,  p-value: 0.03573
```

Anejo 10 - Resultados Ejercicio 2C

```r
library(foreign)


muni_fiscal <- read.csv("muni_econ_fiscal.csv")

regresion_multiple <- lm(fund_balance_all_funds_long_term_liabilities ~
log(area_square_miles) + log(sum_of_sales_value_of_shipments_or_revenue), data = muni_fiscal)

summary(regresion_multiple)
```

Anejo 11 - Ejercicio 2d- Código Rstudio

```
Call:
lm(formula = fund_balance_all_funds_long_term_liabilities ~ log(area_square_miles) +
    log(sum_of_sales_value_of_shipments_or_revenue), data = muni_fiscal)

Residuals:
    Min      1Q  Median      3Q     Max
-1.1148 -0.4045 -0.1914  0.2057  2.1831

Coefficients:
                                                Estimate Std. Error t value Pr(>|t|)
(Intercept)                                      2.35060    0.89362   2.630   0.0105 *
log(area_square_miles)                          -0.07652    0.14544  -0.526   0.6005
log(sum_of_sales_value_of_shipments_or_revenue) -0.10847    0.05156  -2.104   0.0390 *
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.6918 on 69 degrees of freedom
Multiple R-squared:  0.06523,   Adjusted R-squared:  0.03813
F-statistic: 2.407 on 2 and 69 DF,  p-value: 0.09759
```

Anejo 11 - Ejercicio 2d _ Resultados R-Studio